

GEO 多维度评估指标手册

1. 核心评估维度

维度	定义	说明
引用频率	AI 生成回答中明确提及或引用该内容的次数	引用包括直接引用原文、改写后使用、作为事实依据
引用准确性	AI 引用内容与原文事实的一致性程度	例如价格、材质、功能是否被正确传递，无误导
引用位置权重	引用出现在 AI 回答中的位置（靠前/靠后）	越靠前通常代表越重要，对用户可见性越高
信息保留率	原文中的关键信息点被 AI 保留的比例	例如 10 个卖点，AI 回答了其中几个
结构偏好度	不同内容结构（FAQ / 列表 / 段落）被引用的相对比例	归一化后比较，消除平台差异

2. 实验变量对应的评估指标

根据提案中的 5 类自变量，每一类组合下需要测量以下指标：

自变量	水平示例	测量的关键指标
内容结构	FAQ / 列表 / 段落	引用频率、信息保留率、结构偏好度
优先级	核心卖点前置 / 规格前置	引用位置权重、关键信息是否被优先引用
平台	GPT-4o / Gemini / Perplexity	跨平台引用频率一致性、平台特异性偏好

自变量	水平示例	测量的关键指标
场景	通勤 / 户外 / 潮流	引用准确性（场景匹配度）、信息保留率
品类（扩展）	跑鞋 / 防水鞋 / 服装	泛化能力：同一结构在不同品类上的稳定性

3. 数据收集与量化方法

3.1 实验设置

每组变量组合生成 **N 条内容样本**（提案中为 13,500 条有效回复，可抽样）

向每个 LLM 提出**标准化 prompt**（例如：“请介绍这款产品的核心卖点”）

收集 LLM 的完整回答文本

3.2 指标量化公式

① 引用频率

引用频率 = (该内容被引用的回答数) / (总回答数)

- 可进一步区分 **直接引用**（如“根据其描述……”）与 **间接引用**（语义相似但未注明）

② 引用准确性

准确性 = (正确引用的信息点数) / (总信息点数)

- 人工或使用 LLM 评估（如 GPT-4 打分 1~5）

③ 信息保留率

保留率 = (AI 回答中包含的原文卖点数) / (原文总卖点数)

- 卖点需预先定义（例如从列表中提取 8 个关键属性）

④ 位置权重

位置分 = 1 - (首次出现位置 / 回答总长度)

- 位置越靠前得分越高。可设定“前 20% 为高权重”。

⑤ 结构偏好度（归一化）

偏好度 = (某结构引用频率) / (所有结构平均引用频率)

- 大于 1 表示该结构更受偏好。

4. 多维度综合得分（可选）

为简化对比，可计算 **GEO 效能指数**：

GEO 效能指数 = 0.4×引用频率 + 0.2×准确性 + 0.2×保留率 + 0.1×位置分 + 0.1×稳定性(跨平台方差倒数)

权重可根据项目重点调整。

5. 评估执行流程

步骤	活动	产出
1	定义产品内容及关键卖点	卖点清单、结构化内容（FAQ/列表/段落）
2	配置实验 prompt 和 LLM 平台	标准化提问模板
3	收集回答数据	原始回答文本集
4	标注引用情况（可用脚本或人工）	引用次数、位置、准确性标签
5	计算上述指标	各维度分数表
6	统计分析（方差分析、偏好度排序）	结论：哪种结构在哪个平台表现最优